

Árboles (CARTs)

Big Data y Machine Learning para Economía Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Motivación

- Queremos predecir:


$$Price = f(\text{structural attributes}, \text{amenities}, \dots) \quad (1)$$

- Podemos aplicar linear regression,

$$Price = \beta_0 + \beta_1 \text{Habitaciones} + \beta_2 \text{DCBD} + u \quad (2)$$

- Aplicar OLS a este problema requiere tomar algunas decisiones.

Motivación




Agenda

- 1 Árboles: Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 Sobreajuste

Árboles: que hacen?


- 1 Y es la variable a predecir, los insumos son X_1 y X_2
- 2 Partimos el espacio (X_1, X_2) en dos regiones, en base a una sola variable .
- 3 Punto: elegir la variable y el punto de partición de manera óptima.



Habitaciones


Árboles: que hacen?

- 1 Y es la variable a predecir, los insumos son X_1 y X_2
- 2 Partimos el espacio (X_1, X_2) en dos regiones, en base a una sola variable .
- 3 Punto: elegir la variable y el punto de partición de manera óptima.
- 4 Continuamos partiendo





Árboles: que hacen?

- 1 Y es la variable a predecir, los insumos son X_1 y X_2
- 2 Partimos el espacio (X_1, X_2) en dos regiones, en base a una sola variable .
- 3 Punto: elegir la variable y el punto de partición de manera optima (mejor ajuste global.
- 4 Continuamos partiendo



Árboles: que hacen?



Agenda

- 1 Árboles: Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 Sobreajuste

¿Cómo construimos un árbol de decisión?

Problemas de regresión

- ▶ Datos: $y_{n \times 1}$ y $X_{n \times p}$
- ▶ Definiciones
 - ▶ j es la variable que parte el espacio y s es el punto de partición
 - ▶ Defina los siguientes semiplanos

$$R_1(j, s) = \{X | X_j \leq s\} \ \& \ R_2(j, s) = \{X | X_j > s\} \quad (3)$$

- ▶ El problema: buscar la variable de partición X_j y el punto s de forma tal que

$$\min_{j, s} \left[\min_{y_{R_1}} \sum_{x_i \in R_1(j, s)} (y - y_{R_1})^2 + \min_{y_{R_2}} \sum_{x_i \in R_2(j, s)} (y - y_{R_2})^2 \right] \quad (4)$$

¿Cómo construimos un árbol de decisión?

- ▶ ¿Cuál es la solución?

¿Cómo construimos un árbol de decisión?




photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Agenda

- 1 Árboles: Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 **Sobreajuste**

Sobreajuste



Sobreaajuste. Algunas soluciones

- ▶ Fijar la profundidad del árbol.
- ▶ Fijar la cantidad de hojas.
- ▶ Fijar la mínima cantidad de datos que están contenidos dentro de cada hoja.
- ▶ Pruning (poda).
 - ▶ Dejar crecer un árbol muy grande T_0
 - ▶ Luego cortarlo obteniendo sub-árbol (*subtree*)
 - ▶ Como cortarlo?

Pruning (poda)

- ▶ No es posible calcular el error de predicción usando cross-validation para cada sub-árbol posible
- ▶ Solución: *Cost complexity pruning* (cortar las ramas mas débiles)
 - ▶ Indexamos los arboles con T .
 - ▶ Un sub-árbol $T \in T_0$ es un árbol que se obtuvo colapsando los nodos terminales de otro árbol (cortando ramas).
 - ▶ $[T]$ = número de nodos terminales del árbol T

Pruning (poda)

- Cost complexity del árbol T

$$C_{\alpha}(T) = \sum_{m=1}^{[T]} n_m Q_m(T) + \alpha [T] \quad (5)$$

- donde $Q_m(T) = \frac{1}{n_m} \sum_{x_i \in R_m} (y_i - \hat{y}_m)^2$ para los árboles de regresión
- $Q_m(T)$ penaliza la heterogeneidad dentro de la regresión y el número de regiones
- Objetivo: para un dado α , encontrar el pruning óptimo que minimice $C_{\alpha}(T)$

Pruning (poda)

- Mecanismo de búsqueda para T_α (pruning óptimo dado α).

Resultado: para cada α hay un sub-árbol único T_α que minimiza $C_\alpha(T)$.

- Eliminar sucesivamente las ramas que producen un aumento mínimo en $\sum_{m=1}^{[T]} n_m Q_m(T)$
- Se colapsa hasta el nodo inicial pero va a través de una sucesión de árboles
- T_α pertenece a esta secuencia. (Breiman et al., 1984)

Árboles: cómo lo hacen?

Algoritmo Completo

- 1 Utilizamos particiones recursivas binarias para hacer crecer el árbol
- 2 Para un dado α , aplicamos *cost complexity pruning* al árbol para obtener la secuencia de los subárboles como α .
- 3 Utilizamos K-fold cross-validation para elegir α .
- 4 Tenemos entonces una secuencia de subárboles para distintos valores de α
- 5 Elegimos el α y el subárbol que tienen el menor error de predicción.

Ejemplo



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Comentarios Finales

- ▶ Pros:
 - ▶ Los árboles son muy fáciles de explicar a las personas (probablemente incluso más fáciles que la regresión lineal)
 - ▶ Los árboles se pueden trazar gráficamente y son fácilmente interpretados incluso por no expertos. Variables más importantes en la parte superior
- ▶ Cons:
 - ▶ Si la estructura es lineal, CART no funciona bien
 - ▶ Los árboles no son muy robustos